MODUL PRAKTIKUM

Statistical Machine Learning

Modul 2: Ensemble Tree - Random Forest

Penyusun:

Agung Satrio Wicaksono, S.Mat., M.Si.

Ferdian Bangkit Wijaya, S.Stat., M.Si.

Dr.nat.techn. Weksi Budiaji, S.Si., M.Sc.

LABORATORIUM STATISTIKA

PROGRAM STUDI STATISTIKA

FAKULTAS TEKNIK

UNIVERSITAS SULTAN AGENG TIRTAYASA

CILEGON

2026

HALAMAN PENGESAHAN

Nama Matakuliah	:	Statistical Machine Learning
Kode/SKS	:	STA623204/(2-1)
Nomor Modul	:	2
Judul Modul	:	Ensemble Tree - Random Forest
Pelaksanaan	:	Semester 4
Dosen Pengampu	:	Agung Satrio Wicaksono, S.Mat., M.Si.
		Ferdian Bangkit Wijaya, S.Stat., M.Si.
		Dr.nat.techn. Weksi Budiaji, S.Si., M.Sc.
Asisten Praktikum	:	Zilda Ainun Tazkia
		Rafly Priyantama Ramadhan Bagaskara

Cilegon, 6 Maret 2026

Mengetahui,

Ketua Program Studi	Ketua Tim Penyusun Modul
Dr. Faula Arina, S.Si., M.Si.	Ferdian Bangkit Wijaya, S.Stat., M.Si.
NIP. 197112102005012002	NIP. 199005202024061001

KATA PENGANTAR

Alhamdulillahirabbil'aalamiin penulis panjatkan kepada Allah *subhanahu wa ta'ala* atas segala karunia-Nya sehingga Modul 2 Praktikum Mata Kuliah Statistical Machine Learning dengan judul "**Ensemble Tree - Random Forest**" dapat diselesaikan. Shalawat dan salam semoga selalu terlimpah kepada Nabi Muhammad, keluarganya, dan para sahabatnya. Tujuan disusunnya modul praktikum ini adalah untuk membekali mahasiswa dalam penerapan teori yang telah dipelajari di perkuliahan dalam bentuk praktikum.

Kami mengucapkan terimakasih kepada semua pihak yang turut membantu proses penyusunan Modul Praktikum ini. Masukan dan Saran sangat diharapkan demi penyesuaian materi praktikum terhadap perkembangan keilmuan Statistika di masa yang akan datang.

Cilegon, Maret 2026

Tim Penyusun Modul Praktikum

DAFTAR ISI

KATA PENGANTAR 3
DAFTAR ISI 4
A. TUJUAN PRAKTIKUM 5
B. DASAR TEORI 5
1. Paket R yang Digunakan 5
2. Decision Tree dan Algoritma CART 6
3. Pentingnya Pemilihan Model 6
4. Bias-Variance Trade off 7
5. Bagging 8
6. Random Forest 9
7. Parameter Tuning 10
C.DATA/SOAL/KASUS 11
1. Library R yang digunakan 11
2. Data Set 11
D.PENGOLAHAN DATA/ KASUS 12
1. Pemodelan Random Forest 12
2. Pemodelan Random Forest 12
3. Prediksi dan Evaluasi 13
4. Cross-Validation (rfcv) 13
5. Tuning Parameter 13
6. Interpretasi Model 13
E. PENUGASAN 15
DAFTAR PUSTAKA 17

A. TUJUAN PRAKTIKUM

Setelah mengikuti praktikum ini, mahasiswa diharapkan mampu:

1. Memahami konsep dasar Random Forest
2. Membedakan mekanisme pengacakan
3. Mengimplementasikan prosedur pembangunan model Random Forest
4. Melakukan tahapan pra-pemrosesan data
5. Menginterpretasikan metrik performa model
6. Menyelesaikan permasalahan riil

B. DASAR TEORI

Random Forest (RF) merupakan metode ensemble yang dirancang untuk meningkatkan performa algoritma Classification and Regression Tree (CART). Sebagai salah satu metode supervised learning, kelas target dalam Random Forest sudah diketahui sebelumnya (a priori), di mana tujuan utamanya adalah membangun model (baik untuk kasus klasifikasi maupun regresi) guna memprediksi respon di masa mendatang.

1. Paket R yang Digunakan

Berikut adalah daftar paket (library) R yang akan kita gunakan dalam praktikum ini:

a. tidyverse: Merupakan kumpulan alat untuk manipulasi data; dalam modul ini, kita akan fokus menggunakan fungsi-fungsi dari paket dplyr.
b. ISLR: Paket referensi standar yang menyertai buku "An Introduction to Statistical Learning in R" (James et al. 2013).
c. caret: Pustaka standar untuk machine learning dalam R yang memiliki beragam fitur bawaan. Dari paket ini, kita akan menggunakan fungsi createDataPartition untuk membagi data menjadi set pelatihan (training) dan validasi, serta confusionMatrix untuk menghasilkan metrik evaluasi model. Meskipun caret dapat membangun berbagai model secara sintaksis dalam satu paket, kita akan membedah dua paket berikut secara spesifik untuk tujuan tutorial ini.
d. randomForest: Paket standar yang digunakan untuk mengimplementasikan algoritma Random Forest.

e. rpart: Salah satu paket berbasis algoritma CART (Classification and Regression Tree) asli yang digunakan untuk membangun pohon keputusan tunggal.
f. rpart.plot: Paket tambahan (wrapper) untuk perintah plot yang berfungsi menghasilkan visualisasi diagram pohon keputusan yang lebih estetik dan informatif.

2. Decision Tree dan Algoritma CART

Diskusi mengenai Random Forest (RF) tidak dapat dipisahkan dari pengenalan terhadap Decision Tree dan algoritma CART. Classification and Regression Trees (CART) pertama kali diperkenalkan pada tahun 1984 oleh tim yang dipimpin oleh Leo Breiman (Breiman et al. 1984). Algoritma CART menyediakan mekanisme untuk melakukan pembagian biner (binary splits) secara sekuensial pada variabel-variabel yang diberikan, sehingga menghasilkan struktur keputusan yang menyerupai pohon.
Algoritma ini mampu menghasilkan respon baik untuk model kualitatif (kategorik) maupun kuantitatif (numerik). Dalam prosesnya, ruang keputusan (decision space) diklasifikasikan secara kontinu menggunakan kriteria classification error atau node purity (untuk kualitatif), atau Residual Sum of Squares (RSS) (untuk kuantitatif). Dalam praktikum ini, kita akan fokus pada respon kualitatif dengan tujuan memprediksi ke dalam kelas mana sekumpulan prediktor termasuk.

3. Pentingnya Pemilihan Model

Penting untuk dicatat bahwa tidak semua model memberikan kecocokan (fit) terbaik untuk setiap jenis permasalahan. Sebagaimana diilustrasikan pada Gambar 1:

a. Kiri Atas: Kasus di mana batas keputusan bersifat linear/diagonal. Fungsi regresi atau klasifikasi linear akan memberikan hasil terbaik di sini.
b. Kanan Atas: Jika kita memaksakan Decision Tree (yang membagi ruang secara tegak lurus/searah sumbu) pada pola diagonal, hasilnya akan buruk dan berbentuk "tangga".
c. Kanan Bawah: Kasus yang sangat ideal bagi Decision Tree. Batas keputusannya searah dengan sumbu variabel (X1 dan X2), sehingga pohon dapat membagi ruang secara sempurna dengan sedikit split.
d. Kiri Bawah: Model linear akan gagal total menangkap pola kotak/sekat seperti ini.

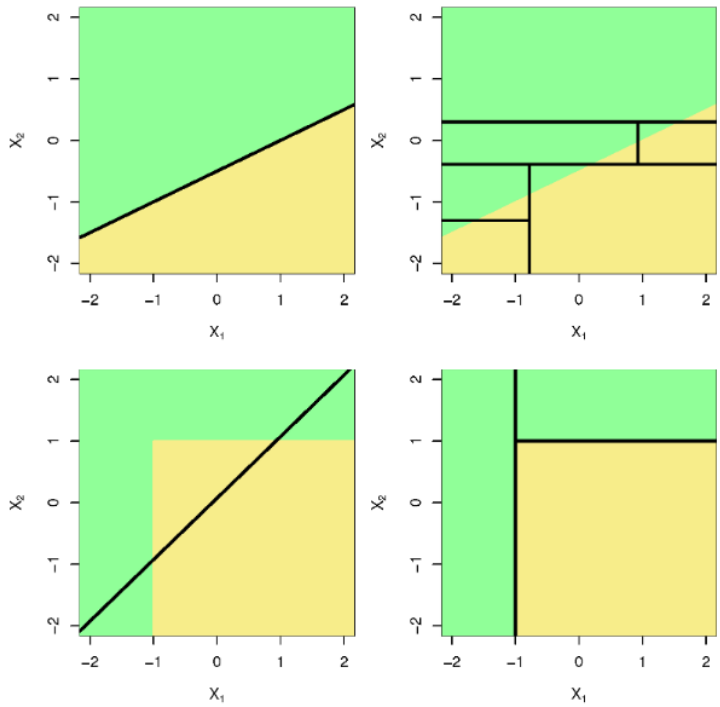

FIgure 1 - Decision Space Stratification (James et al. 2013)

Pemilihan model yang tepat sangatlah krusial. Meskipun algoritma CART dapat diterapkan pada semua skenario di atas, performa yang dihasilkan akan sangat rendah jika model yang dipilih tidak sesuai dengan karakteristik data.

4. Bias-Variance Trade off

Dalam metode klasifikasi apa pun, tujuan utama kita adalah mencapai tingkat akurasi 100% pada data uji (tidak ada false positive maupun false negative), di mana setiap kelas prediksi ditempatkan dengan tepat sesuai dengan hasil sebenarnya. Namun, hal ini menjadi salah satu kelemahan algoritma CART; data yang digunakan dalam satu pembagian (split) data latih/validasi dapat menghasilkan struktur pohon yang berbeda secara signifikan jika dibandingkan dengan pembagian acak lainnya.

Selain itu, model yang memiliki performa baik pada data uji belum tentu memberikan hasil yang sama baiknya saat diberikan data tambahan. Sebagaimana dinyatakan oleh James et al. (2013), "Perubahan kecil pada data dapat menyebabkan perubahan besar pada estimasi pohon akhir." Fenomena ini mencerminkan adanya bias-variance tradeoff. Dalam konteks pohon keputusan, peningkatan kompleksitas model untuk mencapai bias yang rendah sering kali berujung pada varians yang tinggi (model menjadi sangat sensitif/tidak stabil). Sebaliknya, model dengan bias tinggi cenderung terlalu menyederhanakan pola (oversimplification). Meskipun pohon keputusan sangat

berguna sebagai alat visual dalam proses pengambilan keputusan, kinerjanya sering kali terhambat oleh masalah bias dan varians yang tinggi ini.

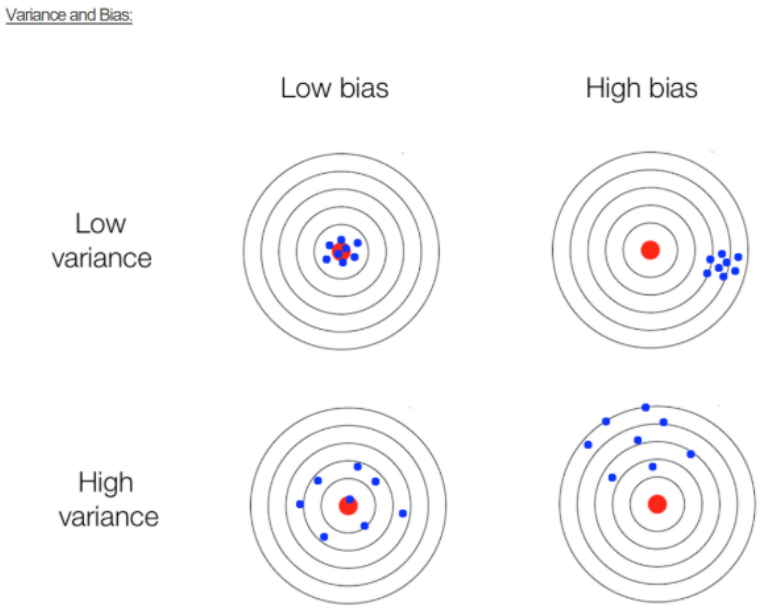

FIgure 2 - Bias-Variance Tradeoff ("Understanding the Bias-Variance Tradeoff: An Overview," n.d.)

Gambar 2 menunjukkan perbedaan antara bias dan varians yang tinggi serta rendah menggunakan analogi papan target:

a. Ideal (Kiri Atas): Low Bias dan Low Variance. Model tidak mengalami overfit dan memiliki konsistensi yang tinggi (tepat sasaran dan mengelompok rapat).
b. Varians Tinggi (Kiri Bawah): Tembakan tersebar jauh dari pusat, menunjukkan model sangat sensitif terhadap perubahan data latihan (overfitting).
c. Bias Tinggi (Kanan Atas): Tembakan mengelompok namun jauh dari pusat, menunjukkan model terlalu sederhana dan gagal menangkap pola asli (underfitting).

Tujuan akhir dari pengembangan model ensemble seperti Random Forest adalah untuk berpindah ke kuadran kiri atas: mengurangi varians tanpa mengorbankan bias secara signifikan.

5. Bagging

Bagging, atau bootstrap aggregating, dikembangkan berdasarkan metode bootstrap (yang telah dibahas pada materi metode resampling). Melalui metode ini, sebanyak n

sampel bootstrap dibuat dari dataset asli, dan kemudian sebanyak n model dilatih berdasarkan masing-masing sampel bootstrap tersebut.

Untuk permasalahan klasifikasi, prediksi akhir ditentukan dengan menghitung rata-rata probabilitas dari seluruh model yang telah dilatih guna menentukan kelas bagi setiap sampel baru. Dengan menerapkan prosedur ini, nilai bias dan varians dapat dikurangi, karena kita beralih dari penggunaan satu pohon tunggal yang kaku menjadi kombinasi dari n pohon unik yang lebih stabil.

6. Random Forest

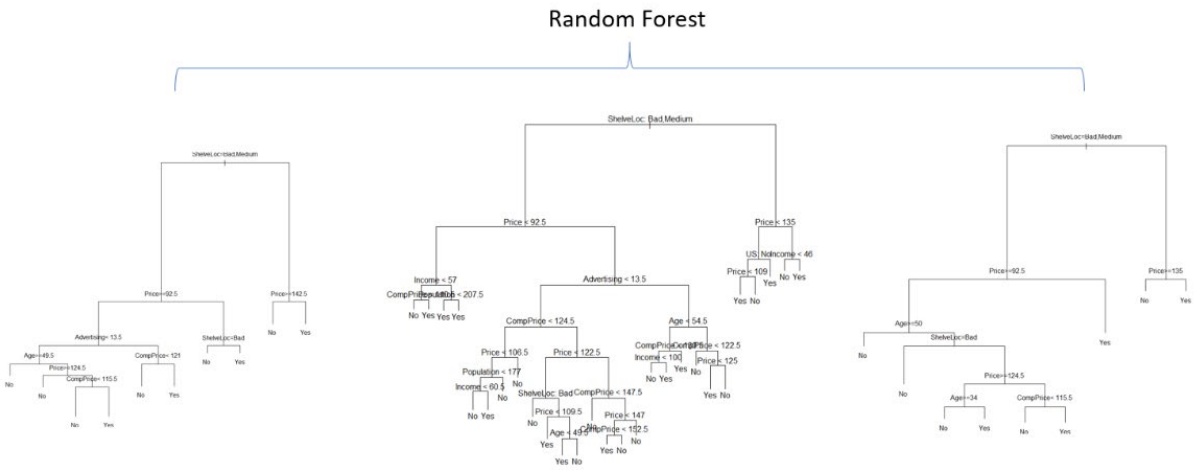

FIgure 3 - 3 Tree Random Forest Example

Melanjutkan konsep bagging, Random Forest memanfaatkan komponen kunci dari bootstrapping dan bagging, yaitu hanya sebagian (subset) sampel dari dataset asli yang digunakan untuk membangun setiap pohon. Secara rata-rata, sekitar dua pertiga dari data diambil sebagai sampel setiap kali prosedur bootstrap dilakukan. Sisa sepertiga observasi yang tidak terpilih disebut sebagai data Out-of-Bag (OOB). Subset OOB ini sangat berguna untuk menguji setiap pohon yang baru dibuat, sehingga menghasilkan estimasi galat OOB (OOB Error) yang dapat digunakan untuk mengukur akurasi model tanpa memerlukan dataset validasi eksternal.

Namun, fitur OOB ini sebenarnya sudah ada pada bagging biasa. Perbedaan utama sekaligus keunggulan kedua dari Random Forest adalah penggunaan subset variabel. Dalam model Random Forest, hanya sebagian kecil variabel prediktor yang dipertimbangkan secara acak saat membangun setiap simpul (node) pohon. Hal ini tidak hanya menghasilkan pohon-pohon yang tidak saling berkorelasi (de-correlated

trees), tetapi juga memastikan bahwa variabel prediktor yang sangat kuat tidak mendominasi (menutupi) variabel lain pada setiap proses pembelahan (split).

Pada intinya, kita membangun banyak pohon di dalam hutan, di mana setiap pohon merupakan kombinasi unik dari sampel observasi dan subset variabel yang berbeda (seperti yang diilustrasikan pada Gambar 3). Model akhir yang dihasilkan terbukti lebih tangguh (robust) terhadap perubahan data di masa depan, serta memiliki bias dan variansi yang lebih rendah dibandingkan dengan model pohon keputusan tunggal.

7. Parameter Tuning

Dalam model Random Forest, terdapat sejumlah hyperparameter yang dapat disetel (tunable). Namun, dalam praktikum ini kita akan membatasi pembahasan pada parameter yang paling krusial saja:

a. ntree: Menentukan jumlah pohon yang akan dibangun di dalam hutan. Semakin banyak pohon biasanya akan membuat model lebih stabil, namun akan meningkatkan beban komputasi.
b. mtry: Jumlah variabel acak yang dipertimbangkan untuk melakukan pembelahan (split) di setiap simpul (node). Ini adalah parameter paling penting untuk mengontrol korelasi antar pohon.
c. classwt: Probabilitas kelas prior. Parameter ini sangat berguna untuk memberikan bobot lebih pada kelas tertentu, terutama saat menangani masalah ketidakseimbangan kelas (imbalanced data).

Di dalam paket randomForest, tersedia juga metode otomatis untuk memilih kondisi optimal bagi parameter-parameter tersebut:

a. rfcv: Metode ini menghitung performa prediksi melalui validasi silang (cross-validation) dengan mengurangi jumlah prediktor secara berurutan. Ini sangat membantu dalam proses seleksi fitur.
b. tuneRF: Fungsi ini digunakan untuk mencari nilai mtry yang paling optimal secara otomatis dengan meminimalkan estimasi galat Out-of-Bag (OOB Error).

C.DATA/SOAL/KASUS

1. Library R yang digunakan

```
install.packages("remotes")
remotes::install_github("araastat/reprtree")
library(tidyverse)
library(ISLR)
library(randomForest)
library(caret)
library(rpart)
library(rpart.plot)
library(reprtree)
```

2. Data Set

Dalam praktikum ini, kita akan menggunakan dua kumpulan data (dataset) dari paket ISLR:

a. Carseats: Merupakan dataset simulasi yang berisi data penjualan kursi mobil anak di 400 toko yang berbeda. Dataset ini akan kita gunakan untuk membangun pohon keputusan (decision tree) sebagai referensi awal sebelum masuk ke pembahasan algoritma Random Forest.

b. Caravan: Merupakan dataset yang berisi 5.882 rekam data pelanggan dengan 85 variabel yang berkaitan dengan keputusan pembelian kursi mobil anak (respon Ya/Tidak). Dataset ini akan digunakan sebagai basis utama dalam membangun model Random Forest.

```
# 1. Persiapan Data
seats <- ISLR::Carseats
seats$High <- as.factor(ifelse(seats$Sales < 8, "No", "Yes"))
# Hapus Sales karena ini adalah variabel asal untuk target 'High'
seats_data <- seats %>% select(-Sales)
seats_data

set.seed(1)
# 2. Split Data (80/20) → Data Pre Processing
train_index <- createDataPartition(seats_data$High, p = 0.8, list =
FALSE)
train_DF <- seats_data[train_index, ]
validate_DF <- seats_data[-train_index, ]

# Memisahkan X dan Y untuk fungsi tuning nanti
train_x <- train_DF %>% select(-High)
train_y <- train_DF$High
validate_x <- validate_DF %>% select(-High)
validate_y <- validate_DF$High
```

D.PENGOLAHAN DATA/ KASUS

1. Pemodelan Random Forest

```
# 3. Membangun Model Random Forest
rf_model <- randomForest(High ~ .,
                         data = train_DF,
                         importance = TRUE,
                         ntree = 500,
                         na.action = na.exclude)
```

2. Pemodelan Random Forest

```
# 4. Visualisasi Variable Importance
varImpPlot(rf_model, main = "Variable Importance - Carseats")
```

3. Prediksi dan Evaluasi

```
pred_y <- predict(rf_model, newdata = validate_DF, type = "class")

# Confusion Matrix
conf_mat <- confusionMatrix(pred_y, validate_y)
print(conf_mat)
```

4. Cross-Validation (rfcv)

```
# Untuk melihat performa jika jumlah prediktor dikurangi secara
bertahap
cv_result <- rfcv(train_x, train_y, cv.fold = 5)
print("Cross-Validation Error per Jumlah Variabel:")
print(cv_result$error.cv)
```

5. Tuning Parameter

```
# Mencari nilai mtry terbaik berdasarkan OOB Error
tune_result <- tuneRF(train_x, train_y,
                      stepFactor = 1.5,
                      improve = 0.01,
                      trace = TRUE,
                      plot = TRUE)
```

6. Interpretasi Model

```
# Melihat struktur pohon ke-1
tree_1 <- getTree(rf_model, k = 1, labelVar = TRUE)
tree_1
reprtree:::plot.getTree(rf_model, k = 1)
```

a. Interpretasi Baris 1 (Simpul Akar / Root Node) : "Apakah harga produk (Price) kurang dari atau sama dengan 106.5?"

   Jika YA (<= 106.5): Data diperintahkan turun ke Baris 2 (left daughter).

   Jika TIDAK (> 106.5): Data diperintahkan turun ke Baris 3 (right daughter).

   Status 1: Berarti ini masih belum selesai, belum ada kesimpulan akhir.

b. Interpretasi Baris 2 (Dahan Kiri) : khusus untuk toko yang harganya sudah murah (<= 106.5), pohon cek lagi: "Apakah harga kompetitornya (CompPrice) juga rendah (<= 121.5)?"

   Jika iya, lanjut ke left daughter baris selanjutnya (misal baris 4). Jika tidak, ke right daughter (baris 5).

c. Interpretasi Baris 3 (Dahan Kanan dari Akar) : Data yang sampai di sini adalah data yang lolos dari Baris 1 dengan kondisi Price > 106.5.

   "Apakah harganya masih di bawah atau sama dengan 149.5?" (Artinya, apakah harganya 'mahal menengah' antara 106.5 - 149.5?).

   Jika YA (<= 149.5): Data diperintahkan turun ke Baris 6 (left daughter).

   Jika TIDAK (> 149.5): Data diperintahkan turun ke Baris 7 (right daughter).

   Ini adalah kelompok "Harga Sangat Mahal".

   Status 1: Masih berupa simpul internal (persimpangan), perjalanan data belum berakhir.

d. Status = 1 (Internal Node): pasti punya angka di left/right daughter dan punya variabel di split var.

   Status = -1 (Terminal Node / Leaf): left/right daughter pasti 0 karena sudah tidak ada jalan lagi.

e. Prediction = <NA> : Muncul jika Status = 1. Karena data masih di tengah jalan, pohon belum berani memberikan vonis "Yes" atau "No".

   Prediction = "Yes" atau "No": Muncul hanya jika Status = -1.

E. PENUGASAN

Data Set

```
set.seed(1)
#load the data
my_data <- ISLR::Caravan
```

Pertanyaan :

1. Data Splitting
   a. Lakukan pembagian data menjadi dua bagian: Training Set (80%) dan Validation Set (20%).
   b. Gunakan fungsi createDataPartition dari paket caret untuk memastikan proporsi kelas pada variabel target tetap seimbang di kedua set data tersebut.
   c. Pisahkan variabel prediktor (x) dan variabel respon (y) baik untuk data latih maupun data validasi.
2. Pembangunan Model Random Forest
   a. Bangun model Random Forest menggunakan fungsi randomForest().
   b. Atur parameter importance = TRUE agar model menghitung tingkat kepentingan masing-masing variabel.
   c. Tambahkan argumen na.action = na.exclude untuk menangani data yang hilang (missing values) jika ada.
3. Analisis Pentingnya Variabel (Variable Importance)
   a. Visualisasikan tingkat kontribusi setiap variabel terhadap akurasi model menggunakan fungsi varImpPlot().
   b. Identifikasi variabel mana saja yang memiliki nilai Mean Decrease Accuracy atau Mean Decrease Gini tertinggi.
4. Prediksi dan Evaluasi Model

   Buatlah Confusion Matrix untuk melihat nilai Akurasi, Sensitivitas, dan Spesifisitas model.
5. Prosedur Validasi Silang
   a. Jalankan fungsi rfcv() untuk melihat bagaimana performa prediksi model jika jumlah variabel dikurangi secara bertahap (sequentially reduced predictors).

b. Amati nilai error.cv yang dihasilkan untuk menentukan jumlah variabel minimal yang masih memberikan performa optimal.

6. Optimasi Hyperparameter
   a. Gunakan fungsi tuneRF() untuk mencari nilai parameter mtry yang paling optimal (yang menghasilkan Out-of-Bag Error terendah).
   b. Atur parameter stepFactor = 2 dan improve = 0.005 untuk mengatur proses pencarian nilai mtry tersebut.
7. Lakukan interpretasi 5 baris pertama untuk Pohon ke-1

DAFTAR PUSTAKA

Joseph F. Hair, Jr., Rolph E. Anderson, Ronald L. Tatham and William C. black, 2014. “Multivariate Data Analysis”, Prentice Hall.

Sharma, Subbash, 1996, “Applied Multivariate Techniques”, John Wiley & Sons.

Johnson, A. Richard and Wichern W. Dean, ” Applied Multivariate Statistical Analysis”, Upper Saddle River, Prentice Hall

Santoso Singgih, (2002), “SPSS Statistik Multivariat”, Gramedia

Ronald E Walpole, Raymond H. Myers, Sharon L. Myers, and Keying Ye, 2002, “Probability and Statistics for Engineers and Scientists, Ninth Edition,” Prentice-Hall, USA

Brieman, L, J Friedman, R Olshen, and C Stone. 1984. Classification and Regression Trees. First. Boca Raton, FL: Chapman; Hall/CRC Press.

James, G, D Witten, T Hastie, and R Tibshirani. 2013. An Introduction to Statistical Learning with Applications in R. Sixth. New York: Springer.

“Understanding the Bias-Variance Tradeoff: An Overview.” n.d. http://www.kdnuggets.com/2016/08/bias-variance-tradeoff-overview.html; Matthew Mayo - KD Nuggets.