# MODUL PRAKTIKUM

## Statistical Machine Learning

## Modul 1: Classification and Regression Tree

**Penyusun:**

**Agung Satrio Wicaksono, S.Mat., M.Si.**
**Ferdian Bangkit Wijaya, S.Stat., M.Si.**
**Dr.nat.techn. Weksi Budiaji, S.Si., M.Sc.**

**LABORATORIUM STATISTIKA**
**PROGRAM STUDI STATISTIKA**
**FAKULTAS TEKNIK**
**UNIVERSITAS SULTAN AGENG TIRTAYASA**
**CILEGON**
**2026**

## HALAMAN PENGESAHAN

| | | |
|---|---|---|
| Nama Matakuliah | : | Statistical Machine Learning |
| Kode/SKS | : | STA623204/(2-1) |
| Nomor Modul | : | I |
| Judul Modul | : | Classification and Regression Tree |
| Pelaksanaan | : | Semester 4 |
| Dosen Pengampu | : | Agung Satrio Wicaksono, S.Mat., M.Si.<br>Ferdian Bangkit Wijaya, S.Stat., M.Si.<br>Dr.nat.techn. Weksi Budiaji, S.Si., M.Sc. |
| Asisten Praktikum | : | Zilda Ainun Tazkia<br>Rafly Priyantama Ramadhan Bagaskara |

Cilegon, 6 Maret 2026

Mengetahui,

| Ketua Program Studi | Ketua Tim Penyusun Modul |
|---|---|
| Dr. Faula Arina, S.Si., M.Si. | Ferdian Bangkit Wijaya, S.Stat., M.Si. |
| NIP. 197112102005012002 | NIP. 199005202024061001 |

## KATA PENGANTAR

Alhamdulillahirabbil'aalamiin penulis panjatkan kepada Allah subhanahu wa ta'ala atas segala karunia-Nya sehingga Modul 1 Praktikum Matakuliah Analisis dan Perancangan Survei dengan judul "Classification and Regression Tree" dapat diselesaikan. Shalawat dan salam semoga selalu terlimpah kepada Nabi Muhammad, keluarganya, dan para sahabatnya. Tujuan disusunnya modul praktikum ini adalah untuk membekali mahasiswa dalam penerapan teori yang telah dipelajari di perkuliahan dalam bentuk praktikum.

Kami mengucapkan terimakasih kepada semua pihak yang turut membantu proses penyusunan Modul Praktikum ini. Masukan dan Saran sangat diharapkan demi penyesuaian materi praktikum terhadap perkembangan keilmuan Statistika di masa yang akan datang.

Cilegon, Maret 2026

Tim Penyusun Modul Praktikum

# DAFTAR ISI

Penyusun: ..... 1
HALAMAN PENGESAHAN ..... 2
KATA PENGANTAR ..... 3
DAFTAR ISI ..... 1
A. TUJUAN PRAKTIKUM ..... 2
B. DASAR TEORI ..... 2
1. Machine Learning ..... 2
2. Decision Tree ..... 3
3. Classification and Regression Tree (CART) ..... 3
4. Kriteria Pemisahan Node ..... 4
5. Regression Tree ..... 5
6. Overfitting dan Tree Pruning ..... 5
7. Implementasi CART di R ..... 5
C. DATA/SOAL/KASUS ..... 6
D. PENGOLAHAN DATA/PENYELESAIAN SOAL/KASUS ..... 6
E. PENUGASAN ..... 8
DAFTAR PUSTAKA ..... 9

## A. TUJUAN PRAKTIKUM

Setelah mengikuti praktikum ini, mahasiswa diharapkan mampu:

1. Memahami konsep dasar Classification and Regression Tree (CART) sebagai metode machine learning berbasis pohon keputusan.
2. Membedakan penggunaan decision tree untuk klasifikasi dan decision tree untuk regresi.
3. Mengimplementasikan algoritma CART menggunakan bahasa pemrograman R.
4. Melakukan visualisasi pohon keputusan.
5. Menginterpretasikan hasil model CART.
6. Melakukan evaluasi sederhana terhadap performa model.

## B. DASAR TEORI

### 1. Machine Learning

Machine Learning merupakan cabang dari *Artificial Intelligence* yang mempelajari metode komputasional yang memungkinkan sistem komputer belajar dari data untuk melakukan prediksi atau pengambilan keputusan tanpa diprogram secara eksplisit untuk setiap tugas tertentu. Dalam pendekatan ini, algoritma dilatih menggunakan data historis untuk menemukan pola atau hubungan antar variabel yang kemudian digunakan untuk melakukan prediksi pada data baru (Mitchell, 1997).

Secara umum, machine learning dapat dibagi menjadi tiga kategori utama, yaitu:

- Supervised Learning, yaitu metode pembelajaran yang menggunakan data dengan variabel target yang telah diketahui. Tujuannya adalah mempelajari hubungan antara variabel input (predictor) dan variabel output (target). Contoh metode supervised learning antara lain regresi linear, decision tree, random forest, dan support vector machine.

- Unsupervised Learning, yaitu metode yang digunakan untuk menemukan pola tersembunyi dalam data tanpa adanya variabel target. Contohnya adalah clustering dan dimensionality reduction.

- Reinforcement Learning, yaitu metode pembelajaran berbasis interaksi antara agen dan lingkungan untuk memaksimalkan suatu fungsi reward.

Materi ini berfokus pada metode *supervised learning* dengan pembahasan metode decision tree yang digunakan untuk masalah klasifikasi dan regresi.

2. Decision Tree

Decision Tree merupakan salah satu metode supervised learning yang menggunakan struktur pohon untuk memodelkan proses pengambilan keputusan. Metode ini bekerja dengan membagi data secara berulang berdasarkan variabel yang paling informatif hingga mencapai kondisi tertentu yang menghasilkan kelompok data yang relatif homogen (Han, Kamber, & Pei, 2012).

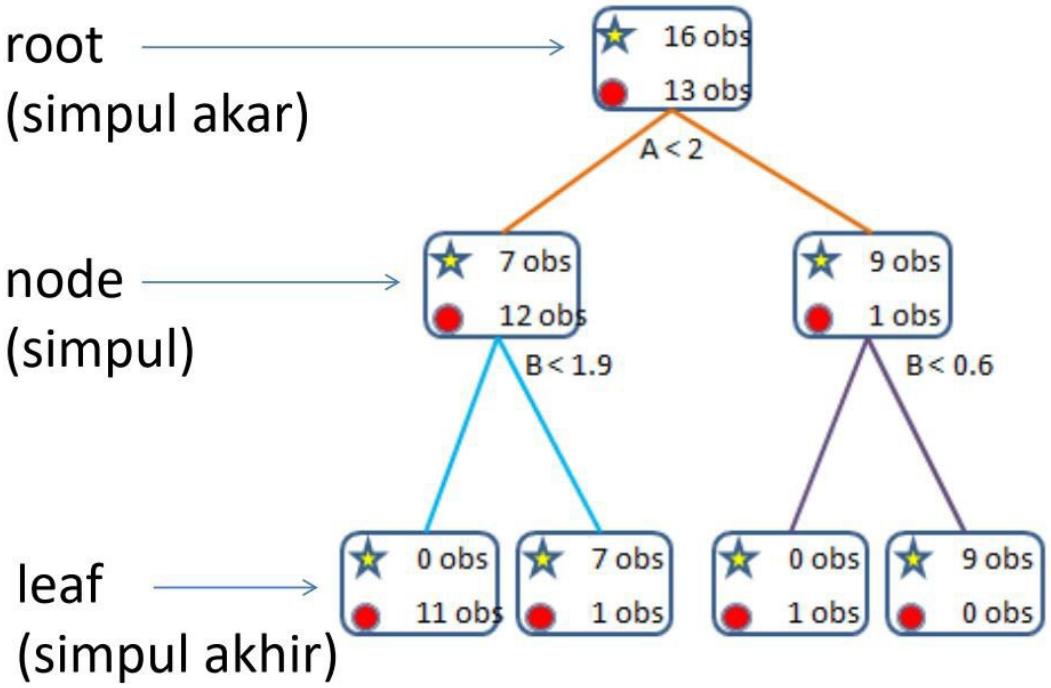


Struktur dasar decision tree terdiri dari beberapa komponen utama, yaitu:

1. **Root (Parent/Simpul Akar)**: Simpul awal yang mewakili seluruh data.
2. **Node (Simpul)**: Simpul yang berisi aturan pemisahan (*splitting rule*) berdasarkan suatu variabel prediktor dengan kriteria tertentu.
3. **Leaf (Terminal/Simpul Akhir)**: Simpul akhir yang menunjukkan hasil prediksi atau klasifikasi.

3. Classification and Regression Tree (CART)

*Classification and Regression Tree* (CART) merupakan algoritma decision tree yang diperkenalkan oleh Breiman, Friedman, Olshen, dan Stone pada tahun 1984. Metode ini digunakan untuk dua jenis analisis utama, yaitu:

1. **Classification Tree**, digunakan ketika variabel target bersifat kategorik. Model bertujuan untuk mengklasifikasikan suatu observasi ke dalam kelas tertentu.

2. **Regression Tree**, digunakan ketika variabel target bersifat numerik atau kontinu. Model bertujuan untuk memprediksi nilai numerik dari variabel target.

Algoritma CART membangun pohon keputusan melalui proses *binary recursive partitioning,* yaitu proses pembagian data secara berulang menjadi dua bagian berdasarkan variabel prediktor tertentu yang memberikan pemisahan terbaik. Proses ini dilakukan hingga memenuhi kriteria penghentian tertentu, misalnya:

- jumlah observasi dalam node terlalu kecil,
- kedalaman pohon mencapai batas tertentu,
- tidak ada lagi peningkatan signifikan dalam kualitas pemisahan.

Setiap node pada pohon akan memilih variabel dan nilai pemisahan (*split point*) yang menghasilkan peningkatan homogenitas terbesar pada node yang dihasilkan.

Sebagai metode nonparametrik, CART tidak memerlukan asumsi tentang bentuk distribusi populasi atau parameter-parameter tertentu dari distribusi tersebut. Metode CART berfokus pada pola dan struktur dalam data tanpa mengandalkan asumsi tertentu tentang model yang mendasarinya.

4. Kriteria Pemisahan Node

Dalam membangun decision tree, diperlukan ukuran untuk menentukan variabel mana yang paling baik digunakan untuk memisahkan data pada setiap node. Ukuran ini disebut *impurity measure* atau ukuran ketidakmurnian.

1. Gini Index

Pada classification tree, salah satu ukuran yang paling umum digunakan adalah Gini Index. Ukuran ini mengukur tingkat ketidakmurnian suatu node. Secara matematis, Gini Index dirumuskan sebagai:

$$Gini(t) = 1 - \sum_{i=1}^{k} p_i^2$$

Di mana:

$p_i^2$ : proporsi observasi pada kelas ke-i
$k$ : jumlah kelas

Nilai Gini berkisar antara 0 hingga 1. Nilai Gini yang lebih kecil menunjukkan bahwa node tersebut lebih homogen. Algoritma CART memilih pemisahan yang menghasilkan penurunan Gini terbesar (*Gini reduction*).

2. Entropy dan Information Gain

Selain Gini Index, ukuran lain yang sering digunakan dalam decision tree adalah entropy yang berasal dari teori informasi. Entropy dirumuskan sebagai:

$$Entropy = 1 \sum_{i=1}^{k} p_i \log_2 (p_i)$$

Entropy yang lebih kecil menunjukkan node yang lebih homogen. Perbedaan entropy sebelum dan sesudah pemisahan disebut information gain, yang menunjukkan seberapa baik suatu variabel memisahkan data. Namun demikian, algoritma CART secara umum lebih sering menggunakan Gini Index, sedangkan entropy lebih umum digunakan pada algoritma ID3 dan C4.5 (Tan, Steinbach, & Kumar, 2019).

5. Regression Tree

Pada regression tree, variabel target bersifat kontinu. Oleh karena itu, ukuran yang digunakan untuk menentukan pemisahan node bukanlah impurity berbasis kelas, melainkan ukuran variasi data, seperti:

- *Mean Squared Error* (MSE)
- *Sum of Squared Error* (SSE)

Tujuan dari pemisahan node adalah meminimalkan variasi nilai target dalam setiap node. Secara umum, model regression tree akan memprediksi nilai target menggunakan rata-rata nilai observasi dalam leaf node.

6. Overfitting dan Tree Pruning

Salah satu masalah utama dalam decision tree adalah overfitting, yaitu kondisi ketika model terlalu kompleks dan menyesuaikan diri secara berlebihan terhadap data pelatihan sehingga performanya menurun pada data baru. Untuk mengatasi masalah tersebut digunakan teknik *pruning*, yaitu proses penyederhanaan pohon dengan menghapus cabang yang tidak memberikan kontribusi signifikan terhadap peningkatan akurasi model.

Algoritma CART menggunakan metode *cost complexity pruning*, yang menyeimbangkan antara kompleksitas model dan tingkat kesalahan prediksi. Proses ini menghasilkan pohon yang lebih sederhana namun memiliki kemampuan generalisasi yang lebih baik.

7. Implementasi CART di R

Dalam bahasa pemrograman R, algoritma CART dapat diimplementasikan menggunakan paket **rpart** (*Recursive Partitioning and Regression Trees)*. Paket ini menyediakan fungsi untuk membangun model decision tree baik untuk klasifikasi maupun regresi. Model CART dapat dibangun menggunakan fungsi sebagai berikut:

```
model <- rpart(Y ~ X1 + X2 + X3, data = dataset, method = "class")
```

Parameter method menentukan jenis analisis yang dilakukan:

- "class" untuk classification tree
- "anova" untuk regression tree

Visualisasi pohon dapat dilakukan menggunakan paket rpart.plot

## C. DATA/SOAL/KASUS

1. Membangun model classification tree menggunakan data **Iris (**yang tersedia di R) untuk mengklasifikasikan jenis bunga (Species) berdasarkan karakteristiknya.

2. Membangun model regression tree menggunakan data **airquality** untuk memprediksi kadar Ozone (Ozone) berdasarkan variabel meteorologi yang tersedia.

## D. PENGOLAHAN DATA/PENYELESAIAN SOAL/KASUS

Kasus 1: classification tree menggunakan data Iris

```
# load dataset
data(iris)
head(iris)

# data explore
str(iris)
summary(iris)
table(iris$Species)

# bagi data training dan testing
set.seed(123)
sample_index <- sample(1:nrow(iris), 0.7*nrow(iris))
train <- iris[sample_index, ]
test <- iris[-sample_index, ]

# load library CART
install.packages("rpart")
install.packages("rpart.plot")
library(rpart)
```

```
library(rpart.plot)

# model dan visualisasi data (menggunakan data train)
model_cart <- rpart(Species ~ ., data=train, method="class")
rpart.plot(model_cart)

# prediksi (menggunakan data test)
prediksi <- predict(model_cart, test, type="class")

# evaluasi model
table(Prediksi = prediksi, Aktual = test$Species) #confusion matrix
mean(prediksi == test$Species) #akurasi
```

Kasus 2: regression tree menggunakan data airquality

```
# load dataset
data(airquality)
head(airquality)

# data explore
str(airquality)
summary(airquality)
dim(airquality)

# penanganan missing value
airquality_clean <- na.omit(airquality)
dim(airquality_clean)

# bagi data training testing
set.seed(123)
n <- nrow(airquality_clean)
train_index <- sample(1:n, size = 0.7*n)
train_data <- airquality_clean[train_index, ]
test_data <- airquality_clean[-train_index, ]
nrow(train_data)
nrow(test_data)

# membuat model regression tree
library(rpart)
library(rpart.plot)
model_tree <- rpart(Ozone ~ ., data = train_data, method = "anova")
summary(model_tree)

# visualisasi model
rpart.plot(model_tree)

# prediksi
prediksi <- predict(model_tree, newdata = test_data)
prediksi

# membandingkan nilai aktual vs prediksi
data.frame( Aktual = test_data$Ozone, Prediksi = prediksi )

# evaluasi model (rmse)
rmse <- sqrt(mean((test_data$Ozone - prediksi)^2))
rmse
```

## E. PENUGASAN

1. Buatlah model **classification tree** menggunakan dataset **Pima Indians Diabetes** yang berisi data medis untuk memprediksi apakah seorang pasien menderita diabetes atau tidak berdasarkan beberapa indikator kesehatan. Gunakan variabel **diabetes** yang memiliki dua kategori: pos (positif diabetes) dan neg (tidak diabetes) sebagai variabel target.
   Dataset dapat diakses melalui package:

   ```
   install.packages("mlbench")
   library(mlbench)
   data(PimaIndiansDiabetes)
   ```

   Berdasarkan hasil yang anda dapatkan:
   a. Variabel apa yang paling penting dalam memisahkan kelas diabetes berdasarkan model decision tree yang terbentuk?
   b. Tuliskan minimal dua aturan keputusan (decision rules) dari pohon klasifikasi yang dihasilkan.
   c. Bagaimana interpretasi hasil klasifikasi yang diperoleh?

2. Buatlah model regression tree menggunakan dataset **Boston Housing** berisi berbagai karakteristik lingkungan dan sosial ekonomi yang berkaitan dengan harga rumah di wilayah Boston. Gunakan variabel **medv** (median value rumah (dalam ribuan dolar)) sebagai variabel target.
   Dataset dapat diakses melalui package:

   ```
   install.packages("MASS")
   library(MASS)
   data(Boston)
   ```

   Berdasarkan hasil yang anda dapatkan:
   a. Variabel apa yang paling berpengaruh dalam memprediksi harga rumah berdasarkan model regression tree yang dihasilkan?
   b. Tuliskan dua aturan keputusan (decision rules) dari pohon regresi yang terbentuk.
   c. Bagaimana interpretasi hubungan antara karakteristik lingkungan dan harga rumah berdasarkan model tersebut?

## DAFTAR PUSTAKA


Breiman, L., Friedman, J. H., Olshen, R. A., & Stone, C. J. (1984). Classification and Regression Trees. Boca Raton: CRC Press.

Han, J., Kamber, M., & Pei, J. (2012). Data Mining: Concepts and Techniques (3rd ed.). Morgan Kaufmann.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). An Introduction to Statistical Learning with Applications in R (2nd ed.). Springer.

Kuhn, M., & Johnson, K. (2013). Applied Predictive Modeling. Springer.

Lantz, B. (2019). Machine Learning with R (3rd ed.). Packt Publishing.

Mitchell, T. M. (1997). Machine Learning. McGraw-Hill.

Tan, P. N., Steinbach, M., & Kumar, V. (2019). Introduction to Data Mining (2nd ed.). Pearson.