Statistical Machine Learning

#5– Ensemble Tree

Ferdian Bangkit Wijaya, S.Stat., M.Si.

Perkembangan Lebih Lanjut dari Pohon Regresi (Ensemble Tree)

Ensemble Tree

1. Bagging
2. Boosting
3. Random Forest
4. Rotation Forest

Kegunaan

1. Pendekatan ensemble tree menghasilkan prediksi yang lebih baik dibandingkan pohon klasifikasi tunggal
2. Ensemble tree banyak digunakan untuk menangani masalah-masalah:
    - Ketidakseimbangan Kelas (Imbalanced Class)
    - Curse of Dimensionality
    - Klasifikasi Multi-Kelas

Bagging (Bootstrap Aggregating)

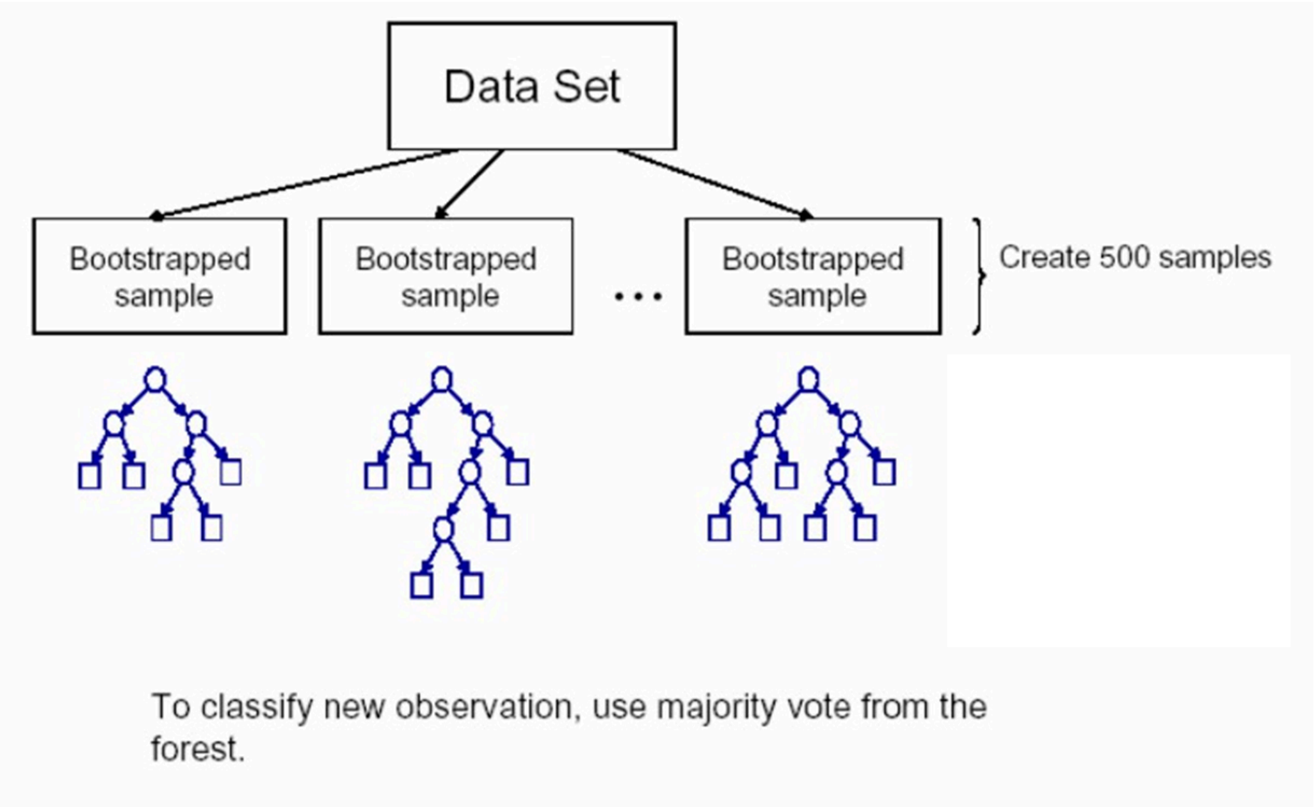

Breiman, L (1996). Bagging predictors. Machine Learning 24 (2): 123–140

1. Jika kita mempunyai n=100 data, maka setiap Bootstrapped Sample ukuran nya juga n=100 (proses resampling dengan pengembalian).
2. Lakukan iterasi selama B=500, maka akan menghasilkan 500 pohon klasifikasi.
3. Jika ada data baru, lakukan voting mayoritas dari 500 pohon (untuk Y kategorik) atau mean (untuk Y kontinu)

Boosting (Bootstrap Aggregating)

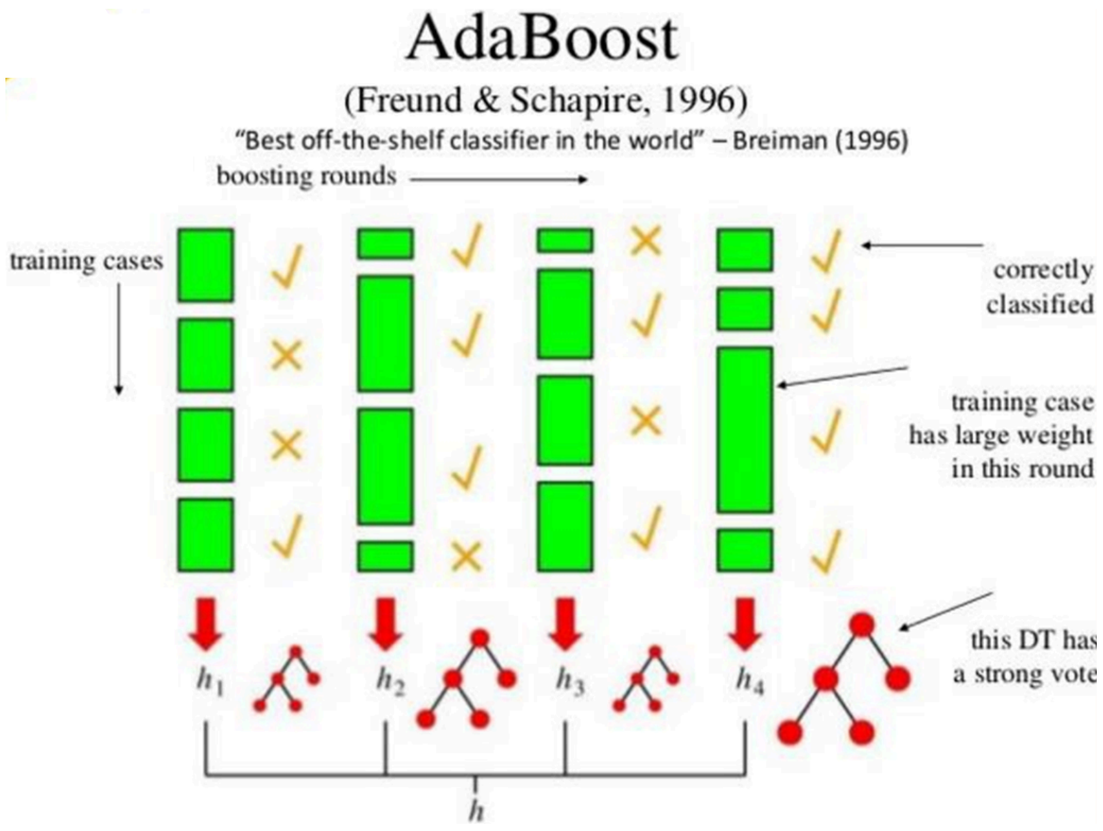

1. Jika kita mempunyai n=100 data, maka akan ada 10 kotak setiap h.
2. Pada h1, semua bobot informasi setiap observasi adalah sama (w_lama=1/100=0.01).
3. Hitung yg salah klasifikasi di h1, misal ada 30 Y yg salah maka Total_error=30*0.01=0.3
4. Hitung power vote :

$$\alpha = \frac{1}{2}\ln\left(\frac{1-\epsilon}{\epsilon}\right)$$

dimana ϵ adalah total_error=0.3 tadi. misal didapatkan $\alpha = 0.42$

5. Hitung w_baru,

Untuk yg tebakan nya salah :

$$w_{baru} = w_{lama} \times e^{\alpha_t} = 0.01 \times e^{0.42} = 0.0152$$

Untuk yg tebakan nya benar :

$$w_{baru} = w_{lama} \times e^{-\alpha_t} = 0.01 \times e^{-0.42} = 0.0065$$

6. Bobot baru menentukan besarnya kotak informasi ke h berikutnya
7. h stop ketika 50-500 pohon.
8. Akumulasi vote untuk data baru adalah

$$H(x) = \text{sign}\left(\alpha_1 h_1(x) + \alpha_2 h_2(x) + \alpha_3 h_3(x) + \cdots + \alpha_T h_T(x)\right)$$

Random Forest

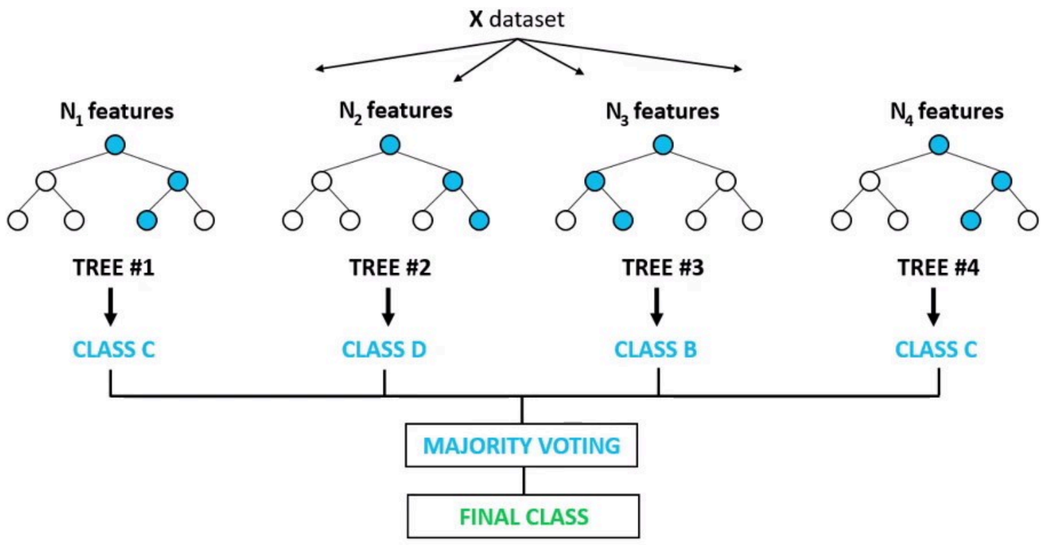

1. Lakukan proses Bagging.
2. Proses Bagging dilakukan dengan pemilihan fitur (X) secara acak dalam splitting pohon.
3. Pemilihan mtry atau jumlah fitur untuk splitting :

Klasifikasi : $m = \sqrt{p}$

Regresi : $m = \frac{p}{3}$

4. Misal kita memiliki 10 variabel $X_1 \ldots X_{10}$

dan kita dapatkan m = 3

5. Misal hasil Bootsraping di Pohon 1 :

- Simpul Akar : random keluar: $\{X_1, X_2, X_3\}$ kemudian dicari Entropy/ IG atau Gini didapat X1 sebagai penyekat.
- Simpul Anak Kiri : random ulang dari 10 variabel asli, misal didapat $\{X_4, X_7, X_9\}$ cari lagi penyekat terbaik
- Simpul Anak Kanan : andom ulang dari 10 variabel asli, misal $\{X_4, X_5, X_8\}$ didapat cari lagi penyekat terbaik.
- Lakukan sampai pohon 1 selesai, 2,3 dst...
- Lakukan sampai proses Bagging selesai.

Rotation Forest

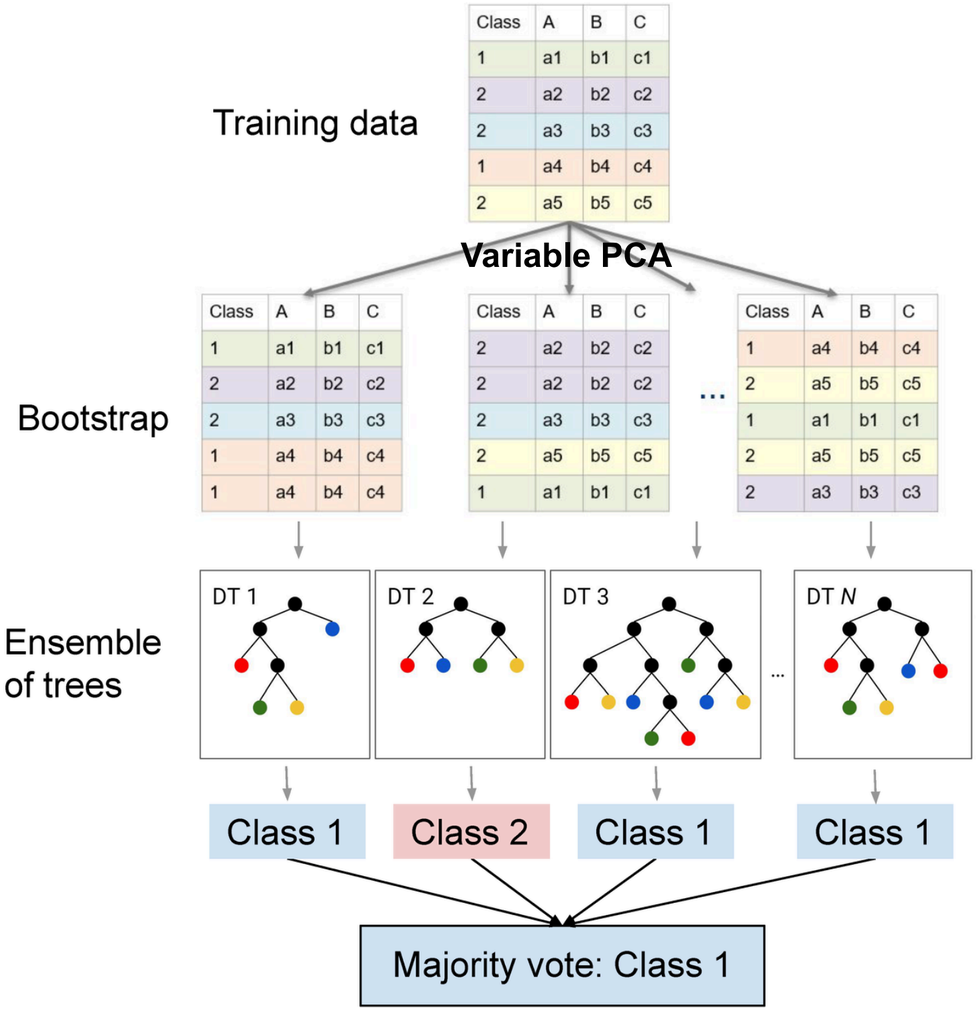

1. Misal ada 10 Fitur $X_1 \ldots X_{10}$
2. Buat Kelompok -K untuk mengelompokkan fitur secara acak. Misal K=2, K=3, hingga K=p (p : banyaknya fitur → Proses Bagging Biasa → Hindari! → pilih K=2 atau 3 agar diversitas pohon terjaga dan rotasi sangat kuat).
3. Misal K=2

Kantong 1 $(G_1) : \{X_1, X_3, X_5, X_7, X_9\}$

Kantong 2 $(G_2) : \{X_2, X_4, X_6, X_8, X_{10}\}$

4. Lakukan Botstraping, misal n= 75% data untuk pohon 1, 2, 3, dst → Bagging/ AdaBoost/ Random forest 100% data
5. Data di Kantong 1 dan 2 diproses pakai PCA
6. Ukuran matriksnya adalah

Saat PCA : $baris \times kolom = (n' \times M) = 75 \times 5$

Output PCA : $baris \times kolom = (M \times M) = 5 \times 5$

7. Buat Rotasi Matriks R $R = baris \times kolom = (p \times p) = 10 \times 10$

$$R = \begin{bmatrix} [5 \times 5]_{Kantong1} & 0 \\ 0 & [5 \times 5]_{Kantong2} \end{bmatrix}$$

8. Lakukan perkalian matriks $X'_{100\times10} = X_{100\times10} \times R_{10\times10}$
9. Gunakan X baru yang sudah dirotasi tersebut sebagai input pembuatan pohon 1, 2, dst...

Rotation Forest

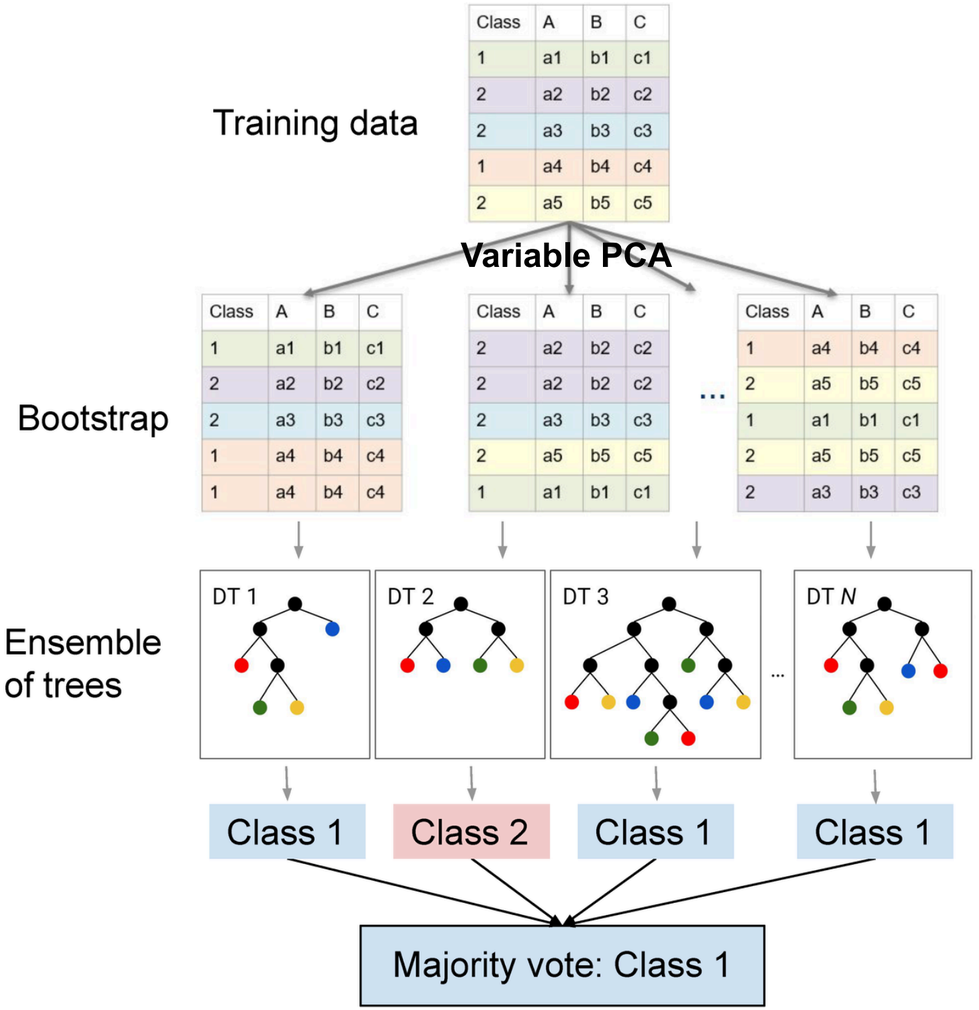

10. Prediksi Data Baru
    - Jangan langsung dimasukkan ke pohon!
    - Data x_{new} harus diputar dulu menggunakan matriks rotasi masing-masing pohon.
    - Untuk Pohon 1: $x_1' = x_{new} \times R_1$ → Masuk ke Pohon 1.
    - Untuk Pohon 2: $x_2' = x_{new} \times R_2$ → Masuk ke Pohon 2.

Terima Kasih