Statistical Machine Learning

#3 – Support Vector Machine

Support Vector Machine

- Pendahuluan
- Hyperplane
- Konsep Margin
- Hard Margin vs Soft Margin
- Cost Parameter
- Lagrange Function

ML Fundamental

Pelajari:

- Bias-Variance Trade-off: https://www.youtube.com/watch?v=EuBBz3bI-aA
- Cross validation: https://www.youtube.com/watch?v=fSytzGwwBVw

7.3 The Bias–Variance Decomposition

As in Chapter 2, if we assume that $Y = f(X) + \varepsilon$ where $\mathrm{E}(\varepsilon) = 0$ and $\mathrm{Var}(\varepsilon) = \sigma_\varepsilon^2$, we can derive an expression for the expected prediction error of a regression fit $\hat{f}(X)$ at an input point $X = x_0$, using squared-error loss:

$$\begin{aligned}
\mathrm{Err}(x_0) &= E[(Y - \hat{f}(x_0))^2 | X = x_0] \\
&= \sigma_\varepsilon^2 + [\mathrm{E}\hat{f}(x_0) - f(x_0)]^2 + E[\hat{f}(x_0) - \mathrm{E}\hat{f}(x_0)]^2 \\
&= \sigma_\varepsilon^2 + \mathrm{Bias}^2(\hat{f}(x_0)) + \mathrm{Var}(\hat{f}(x_0)) \\
&= \text{Irreducible Error} + \mathrm{Bias}^2 + \text{Variance}. \qquad (7.9)
\end{aligned}$$

The first term is the variance of the target around its true mean $f(x_0)$, and cannot be avoided no matter how well we estimate $f(x_0)$, unless $\sigma_\varepsilon^2 = 0$. The second term is the squared bias, the amount by which the average of our estimate differs from the true mean; the last term is the variance; the expected squared deviation of $\hat{f}(x_0)$ around its mean. Typically the more complex we make the model $\hat{f}$, the lower the (squared) bias but the higher the variance.

Pendahuluan

- *Support vector machines* (SVM) adalah algoritma ML terawasi yang mengklasifikasikan data dengan menemukan garis optimal atau *hyperplane* yang memaksimalkan jarak antara setiap kelas dalam ruang N-dimensi.
- SVM dikembangkan pada tahun 1990-an oleh Vladimir N. Vapnik dan rekan-rekannya, dan mereka mempublikasikan karya ini dalam sebuah makalah berjudul "*Support Vector Method for Function Approximation, Regression Estimation, and Signal Processing*" pada tahun 1995.

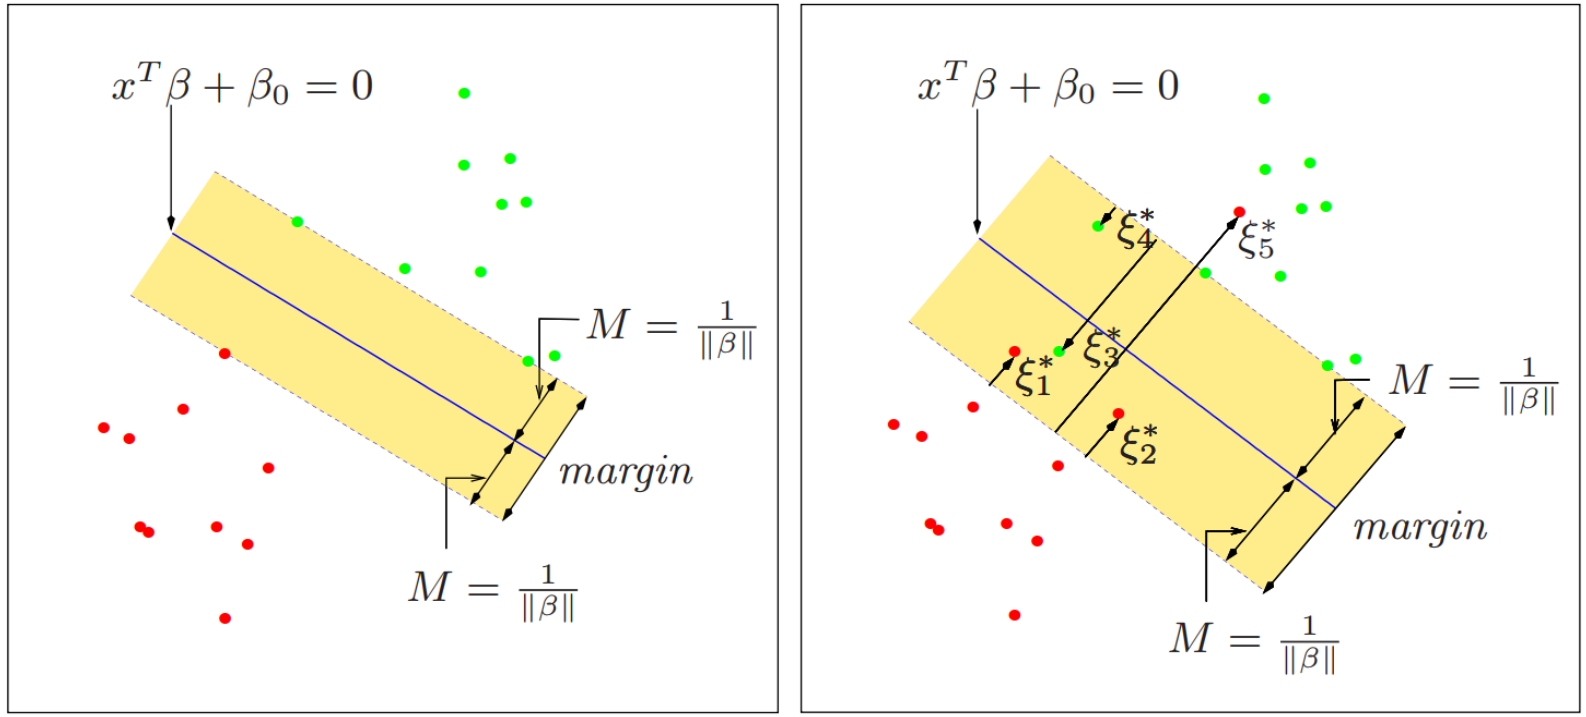

FIGURE 12.1. *Support vector classifiers. The left panel shows the separable case. The decision boundary is the solid line, while broken lines bound the shaded maximal margin of width* $2M = 2/\|\beta\|$. *The right panel shows the nonseparable (overlap) case. The points labeled* ξ_j^* *are on the wrong side of their margin by an amount* $\xi_j^* = M\xi_j$; *points on the correct side have* $\xi_j^* = 0$. *The margin is maximized subject to a total budget* $\sum \xi_i \leq$ *constant. Hence* $\sum \xi_j^*$ *is the total distance of points on the wrong side of their margin.*

Hyperplane

- Hyperplane adalah sebuah garis (pada 2D) atau bidang (pada 3D) yang digunakan oleh SVM untuk memisahkan kelas-kelas data dalam suatu ruang fitur. Dalam dimensi yang lebih tinggi, hyperplane adalah generalisasi dari konsep ini ke dalam ruang multidimensi.
- Tujuan utama SVM adalah menemukan hyperplane yang secara optimal memisahkan data ke dalam kelas yang berbeda.

Hyperplane

Misalkan kita memiliki data training sebanyak N pasangan (x_i, y_i) dengan:

- $x_i \epsilon \mathbb{R}^P$ → fitur input
- $y_i \epsilon (-1,1)$ → label kelas

Sebuah hyperplane didefinisikan sebagai:

$$\{x: f(x) = x^T\beta + \beta_0 = 0\}$$

dengan vektor normal β yang ternormalisasi $||\beta|| = 1$

- Aturan Klasifikasi

$$G(x) = sign(x^T\beta + \beta_0)$$

Jika $G(x) = 1$ maka x diklasifikasikan ke kelas +1, dan sebaliknya untuk -1

Konsep Geometri Hyperplane

- Fungsi $f(x) = x^T\beta + \beta_0$ memberikan jarak bertanda dari titik x ke hyperplane
- Jika kelasnya separable, kita bisa mencari **hyperplane optimal** yang memaksimalkan **margin**.
- Setiap titik data harus berada di **sisi yang benar dari hyperplane**, yang berarti:

$$y_i f(x_i) > 0, \qquad \forall i$$

- **Margin terbesar** diperoleh dengan **mengoptimalkan** jarak ke titik terdekat di kedua kelas.

Optimasi Hard-Margin SVM

- Untuk mencari **hyperplane optimal**, kita menyelesaikan masalah optimasi:

$$\max_{\beta,\beta_0,\|\beta\|=1} M$$

Subject to:

$$y_i\left(x_i^T\beta + \beta_0\right) \geq M, \qquad i = 1, \dots, N$$

Makna constraint:

- y_i mrp label kelas (+1 atau -1)
- x_i mrp vektor untuk titik data ke$-i$
- Contsraint tsb memastikan bahwa **semua titik data berada di sisi yang benar dari hyperplane**, dengan margin minimal M
- M adalah **margin** antara **hyperplane dan titik terdekat**, dengan **lebar margin total** adalah $2M$
- Model dengan **margin lebih besar** lebih tahan terhadap **overfitting**.

Soft-Margin SVM

- Jika data **tidak sepenuhnya dapat dipisahkan secara linear**, kita memperbolehkan **beberapa titik berada di sisi yang salah** dengan menggunakan **slack variable** ξ_i
- Dua bentuk constraint:
  - $y_i\left(x_i^T\beta + \beta_0\right) \geq M - \xi_i$ (menghitung **jarak aktual dari margin**, menghasilkan optimasi non-konveks)
  - $y_i\left(x_i^T\beta + \beta_0\right) \geq M(1 - \xi_i)$ (menghitung **jarak relatif dari margin berdasarkan lebar margin M**, menghasilkan optimasi konveks → cenderung lebih disukai dalam implementasi SVM)

Optimasi Soft-Margin SVM

- Untuk mencari **hyperplane optimal**, kita minimumkan $\| \beta \|$ sambil memastikan bahwa mayoritas titik data berada di sisi margin yang benar. Persamaannya menjadi:

$$\min \|\beta\| \quad \text{subject to} \begin{cases} y_i(x_i^T \beta + \beta_0) \geq 1 - \xi_i \ \forall i, \\ \xi_i \geq 0, \ \sum \xi_i \leq \text{constant}. \end{cases}$$

Interpretasi:

- Jika variabel slack $(\xi_i) = 0$, titik tsb berada di luar margin atau tepat di batas margin
- Jika $0 < \xi_i \leq 1$, titik tsb berada di dalam margin tetapi masih diklasifikasikan dengan benar
- Jika $\xi_i > 1$, titik tsb salah klasifikasi

Optimasi Soft-Margin SVM

- Dengan **membatasi jumlah total** $\sum \xi_i$, kita mengontrol seberapa banyak pelanggaran margin yang diperbolehkan, sehingga mengatur ***trade-off*** antara **margin yang lebih besar** dan **kesalahan klasifikasi yang lebih sedikit** (ingat konsep trade-off bias & variance!)
- Hyperplane optimal ditemukan dengan meminimalkan $\| \beta \|$ dan mengontrol $\sum \xi_i$, atau dari persamaan sebelumnya dapat dinyatakan kembali dalam bentuk:

$$\min_{\beta,\beta_0} \frac{1}{2} \|\beta\|^2 + C \sum_{i=1}^{n} \xi_i$$

Subject to:

$$\xi_i \geq 0, \qquad y_i\left(x_i^T \beta + \beta_0\right) \geq 1 - \xi_i, \qquad \forall i$$

Optimasi Soft-Margin SVM

Makna Constraint:

- $y_i\left(x_i^T\beta + \beta_0\right) \geq 1 - \xi_i$ → jika $\xi_i = 0$, maka titik i diklasifikasikan dengan benar di luar margin. Jika $\xi_i > 0$, titik berada di dalam margin atau salah klasifikasi
- $\xi_i \geq 0$ → variabel slack tidak boleh negatif, karena menunjukkan pelanggaran batas margin

Makna parameter C

- C adalah **cost parameter** yang mengontrol **trade-off antara margin yang lebih besar dan jumlah pelanggaran margin** (ξ_i)
- Jika $C \quad \infty$, maka kembali ke **hard-margin SVM** (tanpa pelanggaran margin).

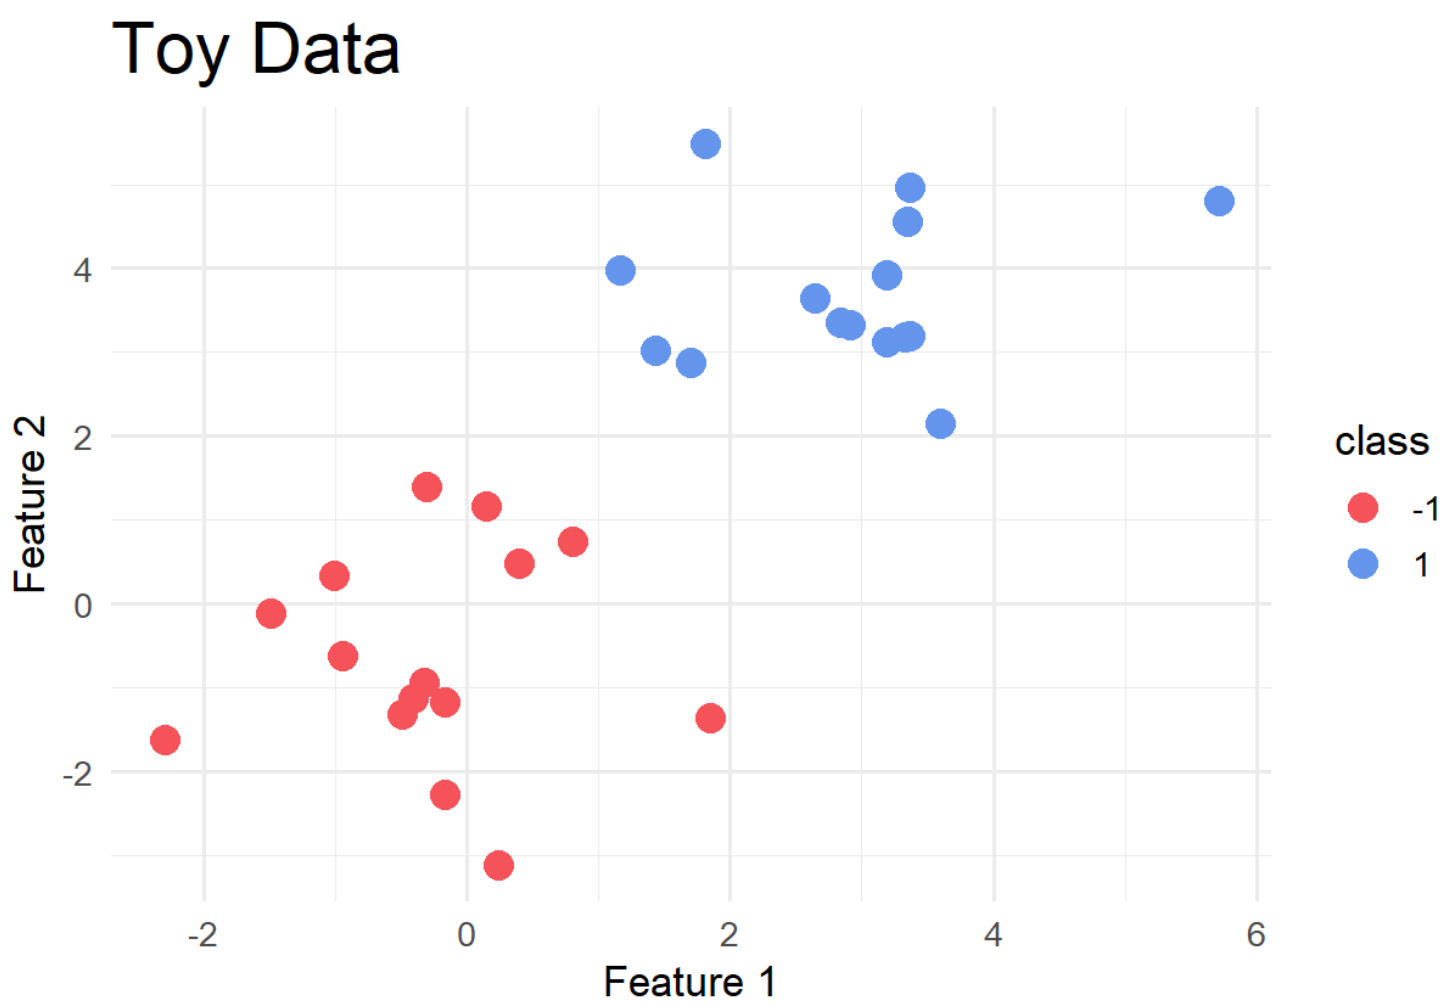
Toy Data
Feature 2
4
2
0
-2
-2
0
2
4
6
Feature 1
class
-1
1

Lagrange Function

The problem (12.7) is quadratic with linear inequality constraints, hence it is a convex optimization problem. We describe a quadratic programming solution using Lagrange multipliers. Computationally it is convenient to re-express (12.7) in the equivalent form

$$\min_{\beta,\beta_0} \frac{1}{2}\|\beta\|^2 + C\sum_{i=1}^{N}\xi_i \qquad (12.8)$$
$$\text{subject to} \quad \xi_i \geq 0,\ y_i(x_i^T\beta + \beta_0) \geq 1 - \xi_i\ \forall i,$$

where the "cost" parameter C replaces the constant in (12.7); the separable case corresponds to $C = \infty$.

The Lagrange (primal) function is

$$L_P = \frac{1}{2}\|\beta\|^2 + C\sum_{i=1}^{N}\xi_i - \sum_{i=1}^{N}\alpha_i[y_i(x_i^T\beta + \beta_0) - (1-\xi_i)] - \sum_{i=1}^{N}\mu_i\xi_i, \quad (12.9)$$

which we minimize w.r.t β, β_0 and ξ_i. Setting the respective derivatives to zero, we get

$$\beta = \sum_{i=1}^{N}\alpha_i y_i x_i, \qquad (12.10)$$
$$0 = \sum_{i=1}^{N}\alpha_i y_i, \qquad (12.11)$$
$$\alpha_i = C - \mu_i,\ \forall i, \qquad (12.12)$$

as well as the positivity constraints $\alpha_i,\ \mu_i,\ \xi_i \geq 0\ \forall i$. By substituting (12.10)–(12.12) into (12.9), we obtain the Lagrangian (Wolfe) dual objective function

$$L_D = \sum_{i=1}^{N}\alpha_i - \frac{1}{2}\sum_{i=1}^{N}\sum_{i'=1}^{N}\alpha_i\alpha_{i'}y_i y_{i'}x_i^T x_{i'}, \qquad (12.13)$$

which gives a lower bound on the objective function (12.8) for any feasible point. We maximize L_D subject to $0 \leq \alpha_i \leq C$ and $\sum_{i=1}^{N}\alpha_i y_i = 0$. In addition to (12.10)–(12.12), the Karush–Kuhn–Tucker conditions include the constraints

$$\alpha_i[y_i(x_i^T\beta + \beta_0) - (1-\xi_i)] = 0, \qquad (12.14)$$
$$\mu_i\xi_i = 0, \qquad (12.15)$$
$$y_i(x_i^T\beta + \beta_0) - (1-\xi_i) \geq 0, \qquad (12.16)$$

for $i = 1, \ldots, N$. Together these equations (12.10)–(12.16) uniquely characterize the solution to the primal and dual problem.